

ПОИСК ХАЙЛАЙТОВ В ВИДЕО

Тулябаева Дина Азаматовна

Сравнение покадрового MLP и Temporal Transformer на MR.HiSum

Цель проекта — построить воспроизводимый пайплайн предсказания важности временных фрагментов видео и проверить, улучшает ли моделирование временного контекста качество по сравнению с независимой обработкой каждого временного шага.

Датасет	MR.HiSum
Экспериментальная выборка	1000 видео
Признаки	YouTube-8M frame-level RGB, 1024 признака
Baseline	MLP
Основная модель	Temporal Transformer
Метрики	MSE и Spearman correlation

Содержание

1. Аннотация
2. Постановка задачи
3. Данные и признаки
4. Подготовка данных
5. Baseline: MLP
6. Основная модель: Temporal Transformer

Используемая среда. Эксперименты выполнялись на CPU под Python 3.11. Для работы использовались PyTorch (обучение моделей), NumPy и pandas (обработка данных), h5py (HDF5), SciPy (Spearman correlation), Matplotlib (визуализация) и TensorFlow только на этапе разбора YouTube-8M SequenceExample. Точные версии пакетов должны быть зафиксированы в requirements.txt репозитория перед сдачей.

7. Экспериментальный протокол

Выбор метрик обусловлен двумя аспектами задачи. MSE оценивает точность абсолютного значения predicted highlight score и сильнее штрафует крупные отклонения. Однако для практического поиска хайлайтов важно не только приблизить численное значение gtscore, но и правильно упорядочить временные фрагменты внутри ролика. Поэтому дополнительно используется ранговая корреляция Спирмена. Global Spearman показывает общее ранжирование всех тестовых временных шагов, а mean per-video Spearman рассчитывается отдельно внутри каждого видео и затем усредняется; эта метрика особенно близка к сценарию выбора лучших моментов каждого конкретного ролика.

8. Результаты

Дополнительный per-video анализ показывает распределение качества, скрытое за средними метриками. На scatter-графике точки выше диагонали соответствуют видео, где Temporal Transformer имеет более высокий Spearman, чем MLP. Таких видео 82 из 150. Гистограмма показывает более широкий разброс Transformer: модель чаще достигает заметно положительной корреляции, но одновременно сохраняет тяжёлый отрицательный хвост.




Рисунок — Распределение per-video Spearman для MLP и Temporal Transformer.




Рисунок — Сравнение per-video Spearman двух моделей; пунктиром показано равенство качества.

9. Анализ ошибок

10. Обсуждение и ограничения

С точки зрения массового применения архитектура допускает отделение тяжёлого этапа извлечения признаков от дешёвого ранжирования: embeddings можно вычислять пакетно и кэшировать, а Temporal Transformer запускать батчами. Частоту временного sampling можно регулировать для компромисса между качеством, latency и стоимостью. При этом в данном учебном прототипе production latency и throughput не измерялись, поэтому масштабируемость является архитектурным преимуществом, а не подтверждённым SLA.

11. Возможные улучшения

12. Выводы

13. Воспроизводимость и структура проекта

1. Аннотация

В работе исследуется задача автоматического поиска хайлайтов в видео как задача предсказания непрерывной оценки важности для последовательности временных фрагментов. Используется датасет MR.HiSum и готовые покадровые визуальные признаки YouTube-8M. Сравниваются две архитектуры: простой MLP, рассматривающий временные шаги независимо, и Temporal Transformer, моделирующий контекст всей последовательности. Эксперимент проведён на 1000 видео с разделением по видео на train/validation/test в пропорции 70/15/15. Основная модель снизила test MSE с 0.08636 до 0.07499, global Spearman увеличился с 0.0254 до 0.1037, а средний per-video Spearman — с -0.0126 до 0.0733. При этом качество заметно варьируется между отдельными роликами, что показывает ограничения готовых визуальных признаков и оптимизации только по MSE.

2. Постановка задачи

Для каждого видео задана последовательность визуальных признаков $X = (x_1, \dots, x_T)$, где x_t — 1024-мерный вектор признаков временного шага. Целевая переменная $y = (y_1, \dots, y_T)$ — gtscore из MR.HiSum, нормированная оценка важности момента в диапазоне от 0 до 1. Необходимо построить функцию $f(X)$, предсказывающую последовательность оценок важности. Важны две стороны качества: близость абсолютных значений к разметке и правильное ранжирование моментов внутри видео.

Основная гипотеза проекта: независимого анализа визуального содержания кадра недостаточно для надёжного поиска хайлайтов, поскольку важность момента зависит от того, что происходило до и после него. Поэтому модель, использующая временной контекст, должна превосходить покадровый baseline.

3. Данные и признаки

3.1. MR.HiSum

MR.HiSum используется как источник целевых оценок важности. В доступном HDF5-файле для каждого video_id содержатся gtscore, gt_summary и change_points. Для обучения в данной работе используется gtscore. Исходный файл не содержал визуальных features, поэтому признаки были восстановлены отдельно из YouTube-8M.

3.2. YouTube-8M frame-level features

Сопоставление MR.HiSum с YouTube-8M выполнялось через metadata.csv: video_id связывался с random_id и соответствующим TFRecord-файлом. Для первых 1000 видео потребовалось 49 train TFRecord-файлов. После загрузки из них извлечены RGB-признаки размерности 1024 и аудиопризнаки размерности 128. В основном эксперименте использованы RGB-признаки; audio оставлен как возможное расширение.

Проверка соответствия прошла для всех 1000 видео: найдено 1000 из 1000, отсутствующих video_id нет. Длины признаков совпали с длинами gt_score; например, video_1 имеет RGB shape (258, 1024) и gt_score длины 258.

4. Подготовка данных

TFRecord-записи YouTube-8M были разобраны как SequenceExample. Квантованные uint8 RGB features деквантовались в float32 и сохранялись в отдельный HDF5-файл yt8m_features_1000.h5. Для каждого видео сохранялись RGB и audio. На этапе построения обучающих выборок дополнительно проверялось равенство числа временных шагов и длины gt_score; mismatches во всех train/validation/test подвыборках равны нулю.

Критически важно, что разделение выполнено по видео, а не по отдельным кадрам. Это предотвращает утечку: временные шаги одного и того же ролика не могут одновременно попасть в train и test.

При выборе подхода рассматривались три уровня сложности. Покадровый MLP выбран как прозрачный и дешёвый baseline, но принципиально не использует временной контекст. Рекуррентные модели (LSTM/GRU) также способны учитывать последовательность, однако Transformer удобнее моделирует дальние зависимости и параллельно обрабатывает временные позиции. Полное end-to-end дообучение тяжёлого video backbone потенциально сильнее, но значительно дороже по памяти и времени. Поэтому для ноутбучного эксперимента и сценария массового применения выбран компромисс: заранее вычисленные и кэшируемые embeddings плюс относительно лёгкая temporal head.

5. Baseline: покадровый MLP

Baseline получает 1024-мерный RGB-вектор одного временного шага и независимо предсказывает его gt_score. Архитектура: Linear(1024→512) + ReLU + Dropout(0.3), затем

Linear(512→128) + ReLU + Dropout(0.2), Linear(128→1) и Sigmoid. Функция потерь — MSE, оптимизатор Adam, learning rate 1e-3.

На validation лучшая точка наблюдалась примерно на второй эпохе: val MSE около 0.0761. После этого train loss продолжал снижаться, но validation не улучшался, что указывает на переобучение. На test MLP получил MSE 0.086356, global Spearman 0.0254 и mean per-video Spearman -0.0126.

6. Основная модель: Temporal Transformer

Основная модель обрабатывает видео как последовательность. Входные признаки проецируются из 1024 в $d_{\text{model}}=128$, к ним добавляется синусоидальное positional encoding. Затем используются два Transformer Encoder слоя с 4 attention heads, размером feed-forward слоя 256 и dropout 0.2. Выход каждого временного шага проходит через небольшой head 128→64→1 с GELU, Dropout и Sigmoid.

Видео имеют различную длину, поэтому внутри batch используется padding и padding mask. MSE вычисляется только по реальным временным шагам. Оптимизатор — AdamW с learning rate 1e-4 и weight decay 1e-4; применяется gradient clipping с max norm 1.0.

7. Экспериментальный протокол

Параметр	Значение
Число видео	1000
Train / validation / test	700 / 150 / 150
Seed	42
Вход	RGB YouTube-8M, 1024
Target	MR.HiSum gtscore
MLP epochs	20, best checkpoint по validation loss
Transformer epochs	20, best checkpoint по validation loss
Основные метрики	MSE, global Spearman, mean per-video Spearman

Для обеих моделей использован один и тот же split. Сохранение лучшего checkpoint по validation loss позволяет оценивать на test не последнюю эпоху, а модель с лучшим обобщением по выбранной функции потерь.

8. Результаты

Модель	Test MSE	Global Spearman	Mean video Spearman
MLP	0.08636	0.0254	-0.0126
Temporal Transformer	0.07499	0.1037	0.0733

Temporal Transformer уменьшил test MSE примерно на 13.2% относительно MLP. Global Spearman вырос примерно в 4.1 раза. Средняя корреляция внутри видео изменилась с отрицательной (-0.0126) на положительную (0.0733), что подтверждает полезность временного контекста для ранжирования моментов.

Per-video анализ показывает, что Transformer имеет меньший MSE на 115 из 150 тестовых видео (76.7%) и более высокий Spearman на 82 из 150 видео (54.7%). Среднее улучшение per-video Spearman составляет +0.0859.

9. Анализ ошибок

9.1. Успешные случаи

Лучший результат Transformer среди выбранных случаев наблюдается на video_258: Spearman увеличивается с 0.0944 у MLP до 0.6869. На video_580 наблюдается крупнейшее улучшение: MLP имеет отрицательную корреляцию -0.3943, тогда как Transformer достигает 0.4884; прирост составляет +0.8827. Такой пример особенно хорошо иллюстрирует ситуацию, когда отдельный кадр недостаточен, а последовательный контекст меняет ранжирование.




Рисунок — Лучший пример Temporal Transformer: video_258 ($\rho=0.687$ против 0.094 у MLP).



Рисунок — Наибольшее улучшение: video_580 ($\rho: -0.394 \rightarrow 0.488$).

9.2. Неудачные случаи

Улучшение не является универсальным. На video_37 MLP показывает 0.5553, а Transformer - 0.3531, то есть изменение равно -0.9083. На video_664 Transformer получает -0.7073 при 0.1322 у MLP. Эти примеры показывают, что temporal attention способен как помогать, так и усиливать неверные зависимости.

На этих графиках видно, что основная проблема обеих моделей — не только величина ошибки, но и недостаточное воспроизведение формы целевой временной кривой. MLP часто предсказывает почти постоянный уровень либо шумные локальные колебания. Transformer обычно формирует более гладкую последовательность, но на отдельных роликах его тренд может быть направлен противоположно ground truth, что приводит к отрицательному Spearman.

Без просмотра исходного видеоконтента нельзя надёжно приписать эти случаи конкретным семантическим категориям (например, динамичным сценам или аудиозависимым моментам), поэтому здесь ошибки категоризируются по наблюдаемому поведению предсказаний.




Рисунок — Наибольшая деградация: video_37 ($\rho: 0.555 \rightarrow -0.353$).




Рисунок — Худший результат Transformer: video_664 ($\rho=-0.707$).

Наблюдаемые типы ошибок: (1) регрессия к среднему — предсказания имеют слишком малую амплитуду; (2) неверный временной тренд — рост/падение score не совпадает с ground truth; (3) локальные ложные пики и пропуски пиков; (4) чрезмерное сглаживание, из-за которого модель не воспроизводит резкие изменения важности.

9.3. Переобучение и конфликт метрик

Лучший validation loss Transformer достигнут на второй эпохе (около 0.06954). Далее train loss монотонно снижался до 0.02640, а validation MSE постепенно ухудшался. Одновременно mean

video Spearman на validation некоторое время продолжал расти. Это важное наблюдение: минимизация MSE и корректное ранжирование моментов — разные цели. Checkpoint, выбранный только по MSE, не обязательно оптимален по Spearman.

10. Обсуждение и ограничения

- Первое ограничение — размер эксперимента: использованы 1000 видео, а не полный MR.HiSum. Это было сделано для воспроизводимого запуска на ноутбуке и CPU.
- Второе ограничение — используются готовые RGB-признаки YouTube-8M. Модель не дообучает визуальный backbone под задачу хайлайтов, поэтому качество ограничено информативностью исходных embeddings.
- Третье ограничение — в основной эксперимент не включён аудиоканал, хотя он был успешно извлечён. Для некоторых хайлайтов звук, речь, аплодисменты или музыкальные события могут быть критичны.
- Четвёртое ограничение — обучение оптимизирует MSE, тогда как для практического выбора лучших моментов более естественна ranking-ориентированная цель.
- Наконец, средний per-video Spearman Transformer остаётся сравнительно небольшим. Следовательно, результат следует интерпретировать как подтверждение преимущества временного моделирования над простым baseline, а не как решение задачи с производственным качеством.

11. Возможные улучшения

- Добавить audio features и исследовать раннее или позднее мультимодальное объединение RGB + audio.
- Использовать более сильные визуальные embeddings, например современные image/video encoders, и сравнить их при неизменной temporal head.
- Оптимизировать комбинацию MSE и ranking loss, либо напрямую использовать pairwise/listwise ranking objective.
- Выбирать checkpoint не только по validation MSE, но и по mean per-video Spearman.
- Увеличить число видео и провести несколько запусков с разными seed для оценки устойчивости.

- Добавить раннюю остановку, scheduler learning rate и более систематический подбор regularization.
- Для production-сценария кэшировать embeddings, использовать batched inference и ограничивать длину/частоту временной выборки для контроля latency и стоимости.

12. Выводы

В проекте построен полный воспроизводимый пайплайн поиска хайлайтов: от сопоставления MR.HiSum с YouTube-8M и извлечения frame-level features до обучения, оценки и анализа ошибок двух моделей. Все 1000 выбранных видео были успешно сопоставлены, а временные размерности features и gtsscore совпали без mismatches.

Главный эксперимент подтверждает исходную гипотезу. Temporal Transformer превосходит покадровый MLP: test MSE снижается с 0.08636 до 0.07499, global Spearman растёт с 0.0254 до 0.1037, mean per-video Spearman — с -0.0126 до 0.0733. Transformer лучше по MSE на 76.7% тестовых видео. Следовательно, временной контекст действительно содержит полезную информацию для определения значимости момента.

Одновременно эксперимент показывает, что одной temporal architecture недостаточно: качество нестабильно между роликами, а оптимизация MSE не полностью соответствует задаче ранжирования. Наиболее перспективные направления продолжения — ranking-aware loss, мультимодальность и более сильные визуальные представления.

13. Воспроизводимость и структура проекта

Основные файлы проекта и их назначение:

- metadata.csv — сопоставление MR.HiSum и YouTube-8M.
- mr_hisum.h5 — целевые gtsscore и вспомогательная разметка.
- yt8m_features_1000.h5 — извлечённые RGB/audio features для 1000 видео.
- extract_features.py — извлечение и деквантование признаков из TFRecord.
- train_mlp.py — обучение baseline.
- train_transformer.py — обучение Temporal Transformer.
- evaluate_mlp_video.py — per-video оценка MLP.

- `analyze_results.py` — сравнение моделей, таблицы и `error analysis`.
- `mlp_baseline.pt` и `temporal_transformer.pt` — сохранённые лучшие `checkpoints`.
- `results/per_video_metrics.csv` — метрики по каждому тестовому видео.
- `results/plots/` — графики для анализа отдельных случаев.